Projet Boréal Assurances

Chaîne de données et analyse du portefeuille d'un assureur auto / habitation

Souleymane DJIBO
M2 Data Analyst · PMN

Projet réalisé seul
Données extraites le 30/06/2025
Dépôt : boreal-DJIBO

Sommaire

Partie	Page
Résumé	2
1. Architecture et ingestion	3
2. Qualité des données et modèle	5
3. Analyse technique du portefeuille	8
4. Clients et sinistres	13
5. Dashboard et documentation	17
Annexes	19

Résumé

Pour ce projet j'ai construit une base de données DuckDB qui charge automatiquement les 68 fichiers fournis (20 264 contrats, 2 805 sinistres, 3 207 lignes de règlements). Les données sont vérifiées (34 règles de qualité, 13 tests), puis organisées en schéma en étoile. Le pipeline tourne en 5 secondes environ et on peut le relancer sans créer de doublons. Le dashboard et ce dossier utilisent les mêmes tables, donc les chiffres sont les mêmes partout (par exemple le ratio sinistres / primes = **58,8 %**).

Ce que j'ai trouvé :

1. Un seul sinistre de 2 475 975 € (collision, 2023) représente 21 % de tout le coût des sinistres. Si on plafonne les sinistres à 150 000 €, le S/P passe de 58,8 % à 46,8 %. La hausse de 2023 (93 %) vient uniquement de ce sinistre.

2. L'habitation rapporte moins que l'auto : S/P de 64,2 % contre 38,8 % (hors gros sinistres), alors que la fréquence est presque la même. La prime habitation est deux fois plus basse. Il y a aussi 1,7 fois plus de sinistres en zone 5 qu'en zone 1, mais la prime n'est que 30 % plus chère.

3. Les clients venus par le web résilient plus (17,9 % par an contre 11,6 % en agence). Et 397 791 € ont été payés sur des sinistres *après* qu'un audit ait confirmé la fraude.

Ce que je propose : suivre le S/P sans les gros sinistres, revoir le prix de l'habitation et des zones à risque, bloquer les paiements quand une fraude est confirmée, et essayer de mieux garder les clients web.

1. Architecture et ingestion

1.1 Schéma de la chaîne

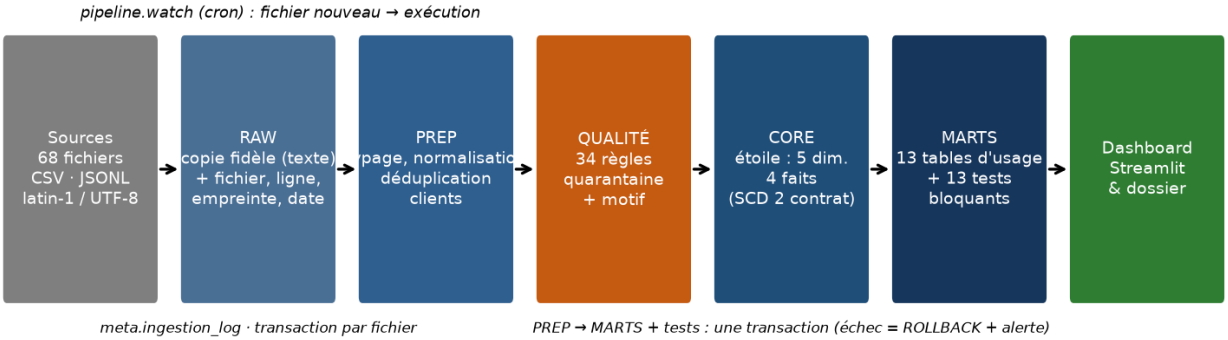


Figure 1 : les différentes couches de la base. Tout est dans un seul fichier DuckDB.

Les données passent par plusieurs étapes. La couche **brute** garde les fichiers tels quels. La couche **préparation** met les bons types (dates, nombres). Ensuite les **contrôles qualité** mettent de côté les lignes à problème (quarantaine). Le **cœur** est le schéma en étoile. Les **marts** sont des tables prêtes à l'emploi pour le dashboard.

Pourquoi ces outils

Outil	Pourquoi je l'ai choisi
DuckDB	Peu de données (41 848 lignes, 610 Ko) : pas besoin d'un serveur. Gratuit, tout tourne en 5 s.
Python + SQL	Ce sont les langages que je maîtrise et le SQL est facile à relire.
Makefile + cron	Une livraison par mois seulement : pas besoin d'Airflow, une ligne de cron suffit.
Streamlit	Gratuit, simple, et le code reste dans le même dépôt. Pages chargées en moins de 2 s.

Avec 100 fois plus de données

DuckDB pourrait encore suivre, mais recalculer toutes les tables à chaque fois deviendrait lent. Je passerais à un chargement mois par mois (dbt incrémental, fichiers Parquet), à une base partagée comme PostgreSQL ou BigQuery si plusieurs personnes travaillent dessus, et à un vrai orchestrateur comme Airflow.

1.2 Chargement des fichiers

Le programme regarde chaque fichier et devine tout seul l'encodage (UTF-8 ou latin-1) et le séparateur (virgule ou point-virgule). Les colonnes sont reconnues par leur nom, pas par leur position. C'était nécessaire car le fichier *reglements_2024_03.csv* n'a pas les colonnes dans le même ordre et la colonne montant s'appelle *montant_eur*. Dans la couche brute je garde tout en texte, et j'ajoute pour chaque ligne le nom du fichier, le numéro de ligne et la date de chargement.

Source	Fichiers	Lignes	Lignes illisibles	Encodage	Séparateur
audits	1	372	0	utf-8	,
clients	1	15 200	0	utf-8	;
contrats	1	20 264	0	utf-8	,
reglements	64	3 207	0	utf-8	,
sinistres	1	2 805	0	utf-8	jsonl

Tableau 1 : résultat du premier chargement.

1.3 Chargement incrémental

Chaque chargement est noté dans une table journal (*meta.ingestion_log*) : nom du fichier, lignes lues, lignes rejetées, durée, statut. Pour éviter les doublons :

- si un fichier a déjà été chargé (même empreinte), il est ignoré ;
- si on recharge un mois, on supprime d'abord ses anciennes lignes puis on les remet ;
- pour les règlements, on n'ajoute que les paiements qui ne sont pas déjà dans la table :

```
INSERT INTO core.fact_reglement
SELECT ... FROM v_reglements r JOIN v_sinistres s USING (sinistre_id)
```

```
WHERE NOT EXISTS (SELECT 1 FROM core.fact_reglement f WHERE f.paiement_id = r.paiement_id);
```

Au deuxième passage, tous les paiements existent déjà, donc la requête n'ajoute rien (le log affiche « 3 174 → 3 174 lignes (+0) »). Pour le prouver, j'ai écrit un test pytest qui recharge le mois d'avril 2023 et vérifie que les tables sont identiques avant et après. Résultat des tests : 5 passed in 94.48s (0:01:34).

Fichier	Mode	Lues	Chargées	Statut	Durée (s)
crm/clients.csv	INITIAL	15200	15200	OK	0,248
crm/clients.csv	SKIP	0	0	IGNORE_DEJA_CHARGE	0,016
reglements/reglements_2023_04.csv	INITIAL	62	62	OK	0,031
reglements/reglements_2023_04.csv	SKIP	0	0	IGNORE_DEJA_CHARGE	0,007
reglements/reglements_2024_03.csv	INITIAL	86	86	OK	0,031
reglements/reglements_2024_03.csv	SKIP	0	0	IGNORE_DEJA_CHARGE	0,009

Tableau 2 : extrait du journal (premier chargement, relance ignorée, rechargement forcé). Commande : make reload MONTH=2023-04.

2. Qualité des données et modèle

2.1 Règles de qualité

J'ai écrit 34 règles. Chacune est une requête SQL qui cherche les lignes qui posent problème. Selon le cas je fais une de ces actions : **exclure** (la ligne part en quarantaine avec la raison), **fusionner** (doublon), **corriger** (la valeur fausse est remplacée par vide) ou **signaler** (on garde la ligne mais on la marque). Si une règle « bloquante » trouve un problème, le chargement s'arrête.

Règle	Table	Contrôle	Gravité	Volume	Traitement
Q01	clients	Date de naissance manquante	mineur	226	signaler
Q02	clients	Date de naissance sentinelle 01/01/1890	majeur	18	corriger
Q03	clients	Âge invraisemblable au 1er contrat (<18 ou >100 ans)	majeur	722	corriger
Q04	clients	Identifiant client dupliqué	bloquant	0	exclure
Q05	clients	Doublon métier (même e-mail + date de naissance)	majeur	200	fusionner
Q06	clients	Région ou CSP hors référentiel	mineur	0	signaler
Q07	contrats	Identifiant contrat dupliqué ou vide	bloquant	0	exclure
Q08	contrats	Contrat rattaché à un client inexistant	majeur	0	exclure
Q09	contrats	Date de résiliation antérieure à la date d'effet	majeur	20	exclure
Q10	contrats	Résiliation le jour de l'effet (durée nulle)	mineur	6	signaler
Q11	contrats	Prime annuelle nulle ou négative	majeur	25	exclure
Q12	contrats	Valeur hors domaine (produit, formule, canal, zone, franchise)	majeur	0	exclure
Q13	contrats	Attributs incohérents avec le produit	mineur	0	signaler
Q14	contrats	Date d'effet manquante ou illisible	majeur	0	exclure
Q15	contrats	Dates postérieures à l'extraction	majeur	0	exclure
Q16	sinistres	Identifiant sinistre dupliqué ou vide	bloquant	0	exclure
Q17	sinistres	Sinistre sur contrat inexistant ou en quarantaine	majeur	5	exclure
Q18	sinistres	Déclaration antérieure à la survenance	mineur	15	signaler
Q19	sinistres	Survenance hors période de couverture du contrat	majeur	18	signaler
Q20	sinistres	Garantie incompatible avec le produit	majeur	0	exclure
Q21	sinistres	Statut incohérent avec la réserve	mineur	0	signaler
Q22	sinistres	Réserve atypique (> 500 k€) : sinistre grave à isoler	mineur	1	signaler
Q23	reglements	Paiement livré plusieurs fois (re-livraison)	majeur	32	exclure
Q24	reglements	Paiement sur sinistre inexistant ou en quarantaine	majeur	1	exclure
Q25	reglements	Montant nul, négatif ou illisible	majeur	0	exclure
Q26	reglements	Paiement avant déclaration ou après extraction	majeur	0	exclure
Q27	reglements	Paiement sur sinistre rejeté ou sans suite	majeur	0	signaler
Q28	reglements	Fichier au schéma non standard (colonnes renommées/permutées)	mineur	86	signaler
Q29	reglements	Paiement hors du mois de son fichier de livraison	mineur	32	signaler
Q30	sinistres	Cumul payé > 2 fois la réserve initiale du sinistre	mineur	17	signaler
Q31	audits	Audit sur sinistre inexistant ou en quarantaine	majeur	0	exclure
Q32	audits	Plusieurs audits pour un même sinistre	majeur	0	exclure
Q33	audits	Audit antérieur à la déclaration ou postérieur à l'extraction	mineur	0	signaler
Q34	audits	Indicateur de fraude hors {0,1}	majeur	0	exclure

Tableau 3 : les 34 règles. 16 trouvent de vrais problèmes. La requête SQL de chaque règle est en annexe E.

Les problèmes principaux

• 20 contrats ont une date de résiliation avant la date de début, et 25 ont une prime à 0 ou négative : je les exclus, ainsi que leurs 5 sinistres et 1 règlement.
• 32 paiements sont livrés deux fois (dans le fichier du mois suivant), pour 73 150,42 €. Le fichier de juillet 2025 (après la date d'extraction) ne contient que des paiements de juin déjà livrés. Je garde la

première livraison.

• Dates de naissance : 226 vides, 18 au 01/01/1890 (valeur bidon) et 722 qui donnent un âge de moins de 18 ans au premier contrat. Je les mets à vide et l'âge devient « Inconnu ».

• 15 sinistres sont déclarés avant d'être arrivés : je les garde pour le coût mais pas pour les délais.

• Un sinistre a une réserve de 1 252 690 €. Ce n'est pas forcément une erreur, je le signale seulement.

Vérification : total des règlements dans les fichiers = 11 294 835,80 € = 11 221 001,06 € gardés + 73 150,42 € de doublons + 684,32 € liés aux contrats exclus. Un test vérifie ça à chaque lancement.

2.2 Doublons clients

Pour trouver les doublons, j'utilise l'e-mail (crypté) + la date de naissance. L'e-mail seul ne suffit pas car deux personnes d'une même famille peuvent avoir le même. J'ai trouvé 200 doublons sur 15 200 clients (1,3 %). Je garde l'identifiant qui a des contrats (sinon le plus petit). Les contrats des autres identifiants sont rattachés au client gardé. Ici, à chaque fois, un seul des deux avait des contrats.

2.3 Schéma en étoile

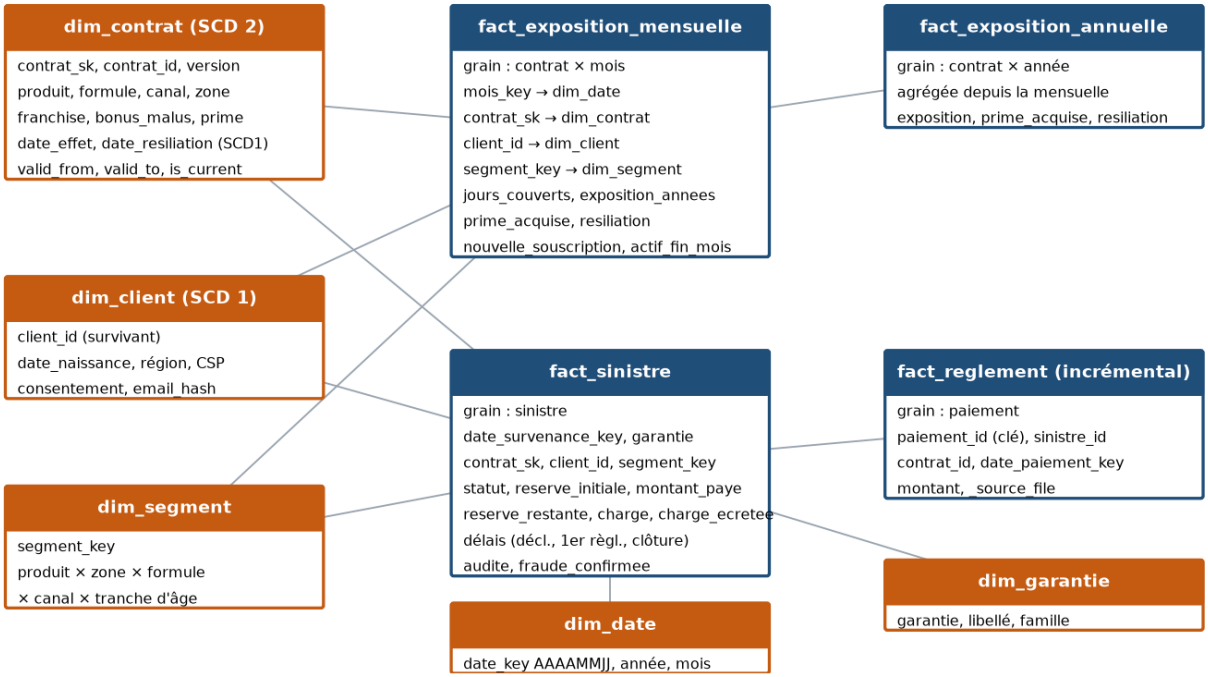


Figure 2 : schéma en étoile (orange = dimensions, bleu = faits).

Table de faits	Une ligne =	Lignes
fact_exposition_mensuelle	un contrat pour un mois	555 226
fact_exposition_annuelle	un contrat pour une année	65 081
fact_sinistre	un sinistre	2 800
fact_reglement	un paiement	3 174

J'ai choisi un grain au mois pour l'exposition car ça permet de calculer facilement n'importe quelle période et de comparer avec l'année d'avant dans le dashboard. La table annuelle est juste la somme des mois. L'exposition est le nombre de jours couverts divisé par 365,25, et la prime acquise = prime annuelle × exposition.

Historique : pour la dimension contrat j'utilise un SCD de type 2 sur les éléments du prix (formule, zone, franchise, bonus-malus, prime). Si un de ces éléments change, on crée une nouvelle version au lieu d'écraser l'ancienne, pour ne pas fausser l'historique. Pour l'instant chaque contrat n'a qu'une version car les données sont une photo à une date.

2.4 Tests

Test	Ce qui est vérifié	Écarts	Statut
T01	Unicité de la clé de substitution et d'une version courante par contrat	0	OK
T02	Unicité des clés client, sinistre et paiement	0	OK
T03	Unicité du grain des faits d'exposition (contrat × mois, contrat × année)	0	OK
T04	Intégrité référentielle des faits vers les dimensions	0	OK
T05	Réconciliation règlements : brut = cœur + quarantaine (lignes et montants au centime)	0	OK
T06	Réconciliation contrats, sinistres, clients et audits : brut = cœur + quarantaine	0	OK
T07	Exposition strictement positive et au plus égale à la durée du mois	0	OK
T08	Aucune date d'événement postérieure à l'extraction	0	OK
T09	Cohérence cœur ↔ marts (primes, exposition, charge, au centime)	0	OK
T10	Montant payé des sinistres = somme des règlements	0	OK
T11	Toute ligne en quarantaine a un motif et une référence source	0	OK
T12	Ratio S/P du mart = ratio recalculé depuis le cœur (écart < 0,01 point)	0	OK
T13	Une version de dim_contrat par contrat sans chevauchement de validité	0	OK

Tableau 4 : les 13 tests lancés à chaque exécution. Si un test échoue, tout est annulé. En plus, 5 tests pytest vérifient les cas de rejeu (5 passed in 94.48s (0:01:34)).

3. Analyse technique du portefeuille

Définitions. Une année-police = un contrat assuré pendant un an (6 mois = 0,5). Je calcule toutes les fréquences par année-police et pas par contrat, sinon un contrat de 2 mois compterait autant qu'un contrat de 5 ans (20 264 contrats ne font que 45 166 années-police). Fréquence = sinistres (ouverts ou clôturés) / années-police. Charge = montants payés + réserve restante des sinistres ouverts. S/P = charge / primes acquises. Le « S/P plafonné » limite chaque sinistre à 150 000 €.

3.1 Payé, réserves et sans suite

	Total	Auto	Habitation
Sinistres déclarés	2 800	1 639	1 161
dont avec suite	1 957	1 026	931
dont sans suite	365	215	150
dont rejetés	478	398	80
Montants payés	11 221 001 €	7 377 811 €	3 843 190 €
Réserves restantes	531 695 €	332 342 €	199 353 €
Charge totale	11 752 697 €	7 710 153 €	4 042 543 €
Primes acquises	19 979 938 €	13 681 257 €	6 298 681 €

Tableau 5 : environ 30 % des déclarations sont sans suite ou rejetées. Les réserves concernent surtout 2024 et 2025, ces chiffres peuvent encore changer.

3.2 Indicateurs par segment

Par produit

Modalité	Années-police	Fréquence	Coût moyen	Prime moy.	S/P	S/P plafonné	Résiliation
AUTO	23 213	4,42 %	7 515 €	589 €	56,4 %	38,8 %	14,2 %
HABITATION	21 953	4,24 %	4 342 €	287 €	64,2 %	64,2 %	14,0 %

Même fréquence, mais la prime habitation est deux fois plus faible. → Il faudrait revoir le prix de l'habitation.

Par zone de risque

Modalité	Années-police	Fréquence	Coût moyen	Prime moy.	S/P	S/P plafonné	Résiliation
1	8 973	3,42 %	5 193 €	388 €	45,8 %	45,1 %	13,8 %
2	11 271	4,05 %	4 768 €	424 €	45,5 %	45,5 %	14,0 %
3	11 288	4,44 %	5 102 €	447 €	50,6 %	49,6 %	14,4 %
4	8 907	4,74 %	9 827 €	482 €	96,6 %	42,4 %	14,2 %
5	4 726	5,73 %	4 727 €	503 €	53,9 %	53,9 %	13,8 %

La fréquence monte de 3,42 % (zone 1) à 5,73 % (zone 5), mais la prime monte peu. → Augmenter l'écart de prix entre zones. (Le S/P de la zone 4 est gonflé par le gros sinistre.)

Par formule

Modalité	Années-police	Fréquence	Coût moyen	Prime moy.	S/P	S/P plafonné	Résiliation
CONFORT	18 029	5,29 %	6 828 €	442 €	81,6 %	52,1 %	13,2 %
ESSENTIELLE	15 210	2,66 %	6 233 €	371 €	44,7 %	43,8 %	16,4 %
PREMIUM	11 927	5,02 %	4 542 €	533 €	42,8 %	42,8 %	12,4 %

Essentielle a peu de sinistres (2,66 %) mais beaucoup de résiliations (16,4 %). Confort a le plus de sinistres (5,29 %). → Vérifier le prix de Confort.

Par canal

Modalité	Années-police	Fréquence	Coût moyen	Prime moy.	S/P	S/P plafonné	Résiliation
AGENT	18 853	4,33 %	8 281 €	444 €	80,7 %	52,0 %	11,6 %
COURTIER	9 317	4,29 %	4 201 €	442 €	40,8 %	40,8 %	12,1 %
WEB	16 996	4,36 %	4 474 €	441 €	44,3 %	44,3 %	17,9 %

Même fréquence sur les trois canaux, mais le web résilie beaucoup plus. → Faire des actions pour garder les clients web.

Par tranche d'âge

Modalité	Années-police	Fréquence	Coût moyen	Prime moy.	S/P	S/P plafonné	Résiliation
18-25	3 143	4,33 %	3 743 €	473 €	34,3 %	34,3 %	14,3 %
26-35	8 184	4,00 %	4 633 €	423 €	43,7 %	42,9 %	13,6 %
36-45	11 202	4,10 %	10 831 €	425 €	104,3 %	54,4 %	14,2 %
46-55	10 522	4,38 %	4 286 €	434 €	43,3 %	43,3 %	13,9 %
56-65	5 948	4,05 %	5 544 €	427 €	52,5 %	52,5 %	13,8 %
66+	3 078	4,22 %	3 944 €	468 €	35,6 %	35,6 %	14,8 %
Inconnu	3 089	6,57 %	4 596 €	557 €	54,3 %	54,3 %	15,1 %

Peu de différences entre âges. Par contre les clients avec un âge « Inconnu » ont plus de sinistres (6,57 %). → Mieux contrôler la saisie de la date de naissance.

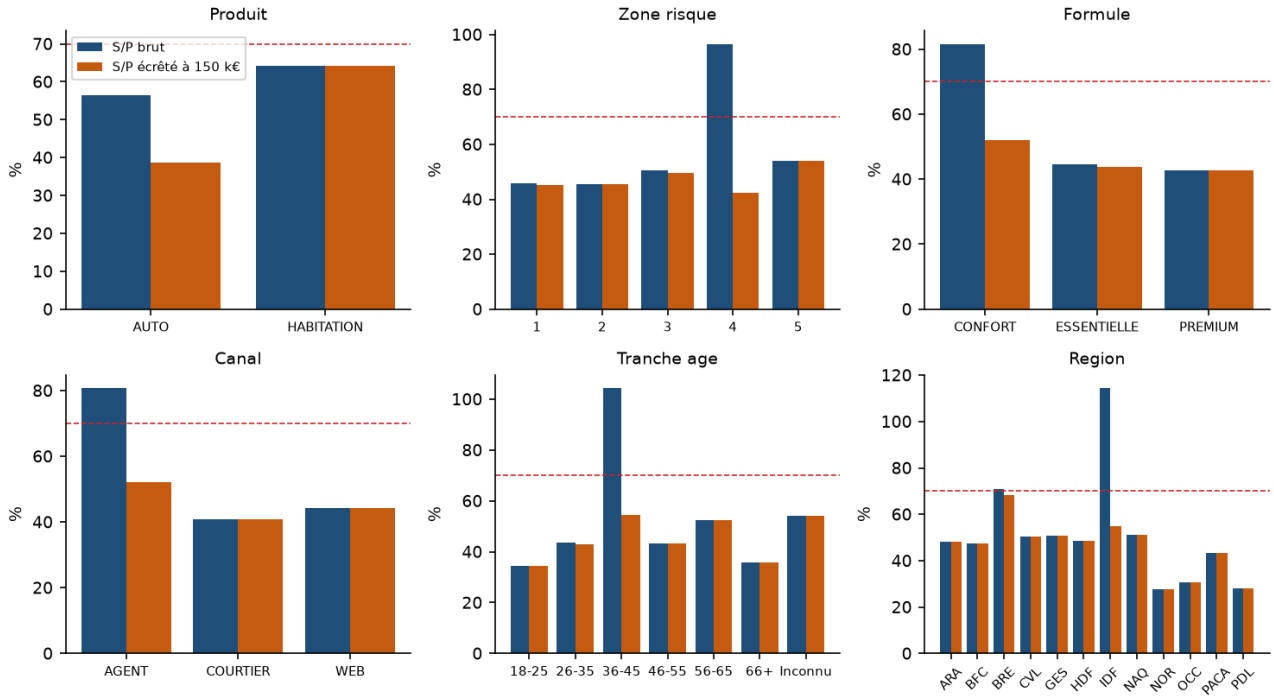


Figure 3 : S/P normal et plafonné par segment (ligne rouge = seuil de 70 %).

3.3 Évolution du S/P année par année

On peut écrire S/P = fréquence × coût moyen / prime moyenne. Le nombre de contrats (volume) n'apparaît pas car il augmente autant la charge que les primes. J'ai donc séparé la variation du S/P en trois parts : fréquence, coût moyen et prime moyenne (méthode LMDI, qui ne laisse pas de reste).

Période	S/P début	S/P fin	Variation	Fréquence	Coût moyen	Prime moy.	Remarque
2020→2021	60,6 %	41,1 %	-19,5 pt	-9,3 pt	-10,2 pt	+0,0 pt	complète
2021→2022	41,1 %	52,2 %	+11,1 pt	+3,3 pt	+7,7 pt	+0,2 pt	complète
2022→2023	52,2 %	92,7 %	+40,4 pt	-7,9 pt	+48,2 pt	+0,2 pt	complète
2023→2024	92,7 %	49,6 %	-43,1 pt	+0,2 pt	-43,4 pt	+0,0 pt	à consolider (réserves encore ouvertes)
2024→2025	49,6 %	44,6 %	-5,0 pt	-2,8 pt	-2,2 pt	+0,0 pt	incomplète (6 mois, sinistres récents non développés)

Tableau 6 : décomposition du S/P (en points).

Période	S/P plafonné fin	Variation	Fréquence	Coût moyen	Prime moy.
2020→2021	41,1 %	-19,5 pt	-9,3 pt	-10,2 pt	+0,0 pt
2021→2022	51,5 %	+10,4 pt	+3,3 pt	+7,0 pt	+0,2 pt
2022→2023	42,8 %	-8,7 pt	-5,3 pt	-3,6 pt	+0,1 pt
2023→2024	48,7 %	+5,9 pt	+0,1 pt	+5,7 pt	+0,0 pt
2024→2025	44,6 %	-4,1 pt	-2,8 pt	-1,3 pt	+0,0 pt

Tableau 7 : même chose avec les sinistres plafonnés à 150 000 €.

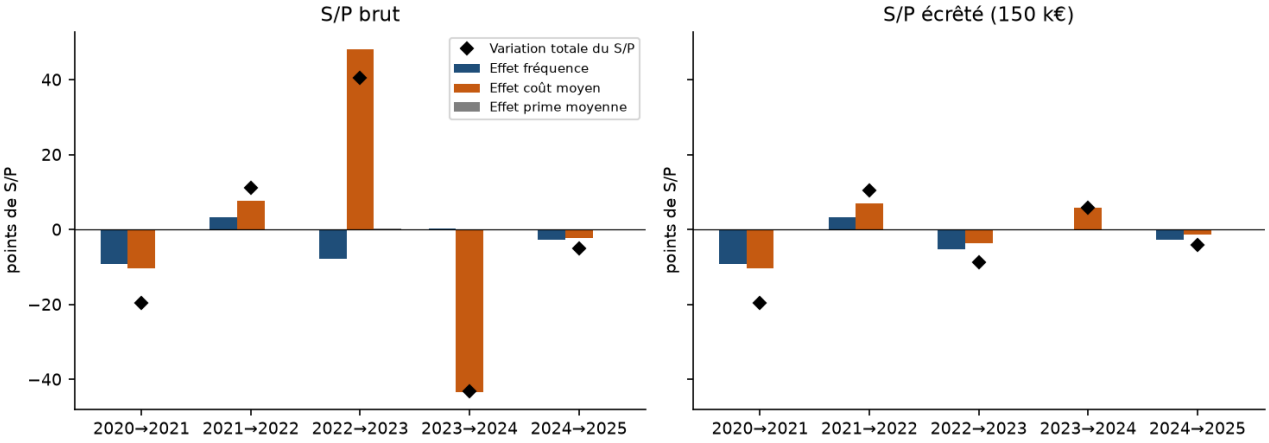


Figure 4 : effets par année.

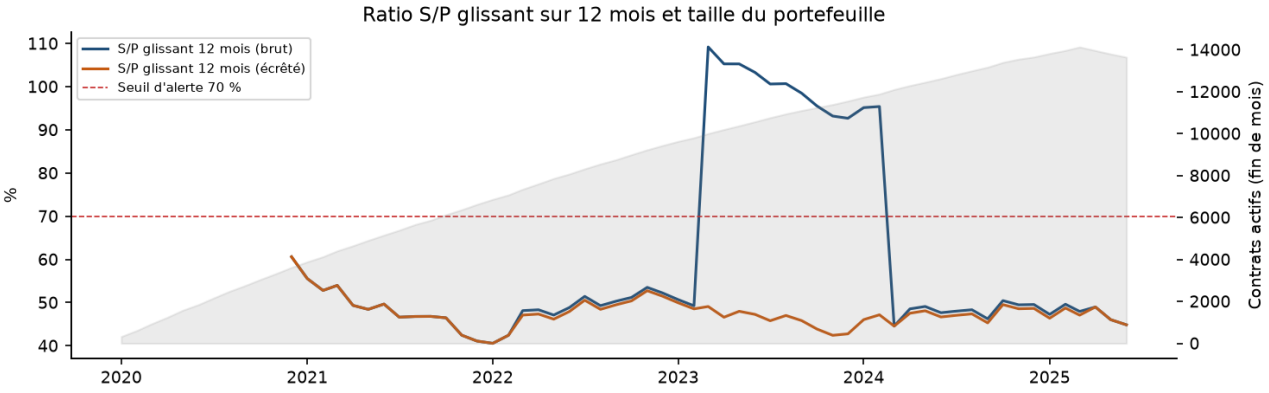


Figure 5 : S/P sur 12 mois glissants et nombre de contrats actifs. Le pic de 2023 correspond au gros sinistre.

Ce qu'on voit : la prime moyenne ne bouge presque pas (environ 442 €). En 2023, le S/P monte de 40,4 points à cause du coût moyen, c'est-à-dire du sinistre de 2,48 M€. Sans ce sinistre, 2023 est même meilleur que 2022 (-8,7 pt). En 2024 le S/P baisse car le gros sinistre n'est plus là. Les segments qui pèsent le plus dans la hausse de 2023 (zone 4, Île-de-France, agence, Confort, 36-45 ans) sont simplement ceux de ce sinistre. Sans lui, la hausse de 2024 vient surtout de la formule

Essentielle (+5,1 pt) et de la zone 3 (+5,1 pt).

Attention aux années incomplètes : 2020 est le démarrage (peu de contrats), 2024 a encore des sinistres ouverts, et 2025 ne fait que 6 mois avec des sinistres récents pas encore tous déclarés. Le S/P 2025 va donc sûrement monter.

3.4 Statistiques

Intervalles de confiance

Indicateur	Valeur	Intervalle de confiance 95 %	Méthode
Fréquence	4,33 %	4,14 % à 4,53 %	loi de Poisson
Coût moyen	6 005 €	4 391 € à 8 822 €	bootstrap (2 000 tirages)
Coût moyen plafonné	4 777 €	4 362 € à 5 239 €	bootstrap (2 000 tirages)
Prime moyenne	442 €	439 € à 446 €	bootstrap (2 000 tirages)
S/P	58,8 %	42,6 % à 87,3 %	bootstrap (2 000 tirages)
S/P plafonné	46,8 %	42,1 % à 52,0 %	bootstrap (2 000 tirages)
Taux de résiliation	14,1 %	13,7 % à 14,4 %	loi de Poisson
S/P plafonné auto	38,8 %	33,5 % à 44,8 %	bootstrap (2 000 tirages)
S/P plafonné habitation	64,2 %	55,4 % à 73,7 %	bootstrap (2 000 tirages)

Tableau 8 : pour la fréquence et la résiliation j'utilise la loi de Poisson (on compte des événements sur une durée). Pour les autres, j'utilise un bootstrap en tirant des contrats au hasard 2 000 fois.

L'intervalle du S/P normal est très large à cause du gros sinistre ; celui du S/P plafonné est beaucoup plus serré. Les intervalles auto et habitation ne se chevauchent pas : la différence est réelle.

Test 1 : fréquence zone 1 contre zone 5

Zone 1 : 307 sinistres pour 8 973 années-police (3,42 %). Zone 5 : 271 pour 4 726 (5,73 %). J'ai utilisé un test exact de comparaison de deux taux de Poisson, adapté à des comptages avec des durées d'exposition différentes. p-value < 0,001 : la différence est significative. La zone 5 a 1,68 fois plus de sinistres (entre 1,42 et 1,97).

Test 2 : coût des sinistres agence contre web

Coût moyen agence 8 281 €, web 4 474 €. Les coûts ne suivent pas une loi normale (quelques sinistres très chers), donc j'ai utilisé le test de Mann-Whitney plutôt qu'un test de Student. Médianes : 2 049 € et 2 008 €, p-value 0,519 : pas de différence significative. L'écart de moyenne vient du gros sinistre (qui est en agence).

Distribution des coûts

Médiane	P75	P90	P95	P99	Maximum	Moyenne
1 997 €	5 013 €	10 762 €	16 472 €	43 187 €	2 475 975 €	6 005 €

Tableau 9 : la moyenne est 3 fois la médiane. Les 1 % de sinistres les plus chers font 34 % du coût total, les 10 % les plus chers 61 %.

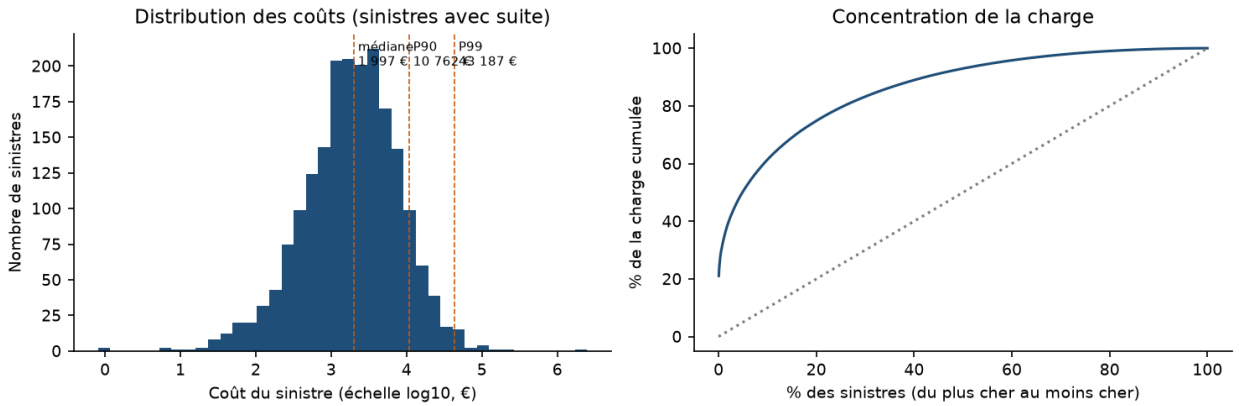


Figure 6 : répartition des coûts (échelle log) et concentration.

4. Clients et sinistres

4.1 Rétention par cohorte

La cohorte = l'année où le client a pris son premier contrat. Un client est « retenu » après k ans s'il a encore un contrat actif. Je n'affiche que les cases où tous les clients ont pu être observés jusqu'au bout (par exemple la cohorte 2023 seulement à 1 an).

Produit	Cohorte	Clients	1 an	2 ans	3 ans	4 ans
auto	2020	2 061	85 %	74 %	62 %	54 %
auto	2021	1 928	87 %	74 %	64 %	
auto	2022	2 004	87 %	75 %		
auto	2023	1 905	86 %			
auto	2024	2 010				
habitation	2020	1 861	86 %	75 %	65 %	57 %
habitation	2021	1 847	86 %	74 %	63 %	
habitation	2022	1 935	86 %	73 %		
habitation	2023	1 848	87 %			
habitation	2024	1 868				
tous	2020	3 697	87 %	79 %	74 %	69 %
tous	2021	3 222	87 %	80 %	74 %	
tous	2022	2 913	88 %	80 %		
tous	2023	2 482	88 %			
tous	2024	2 178				

Tableau 10 : taux de rétention.

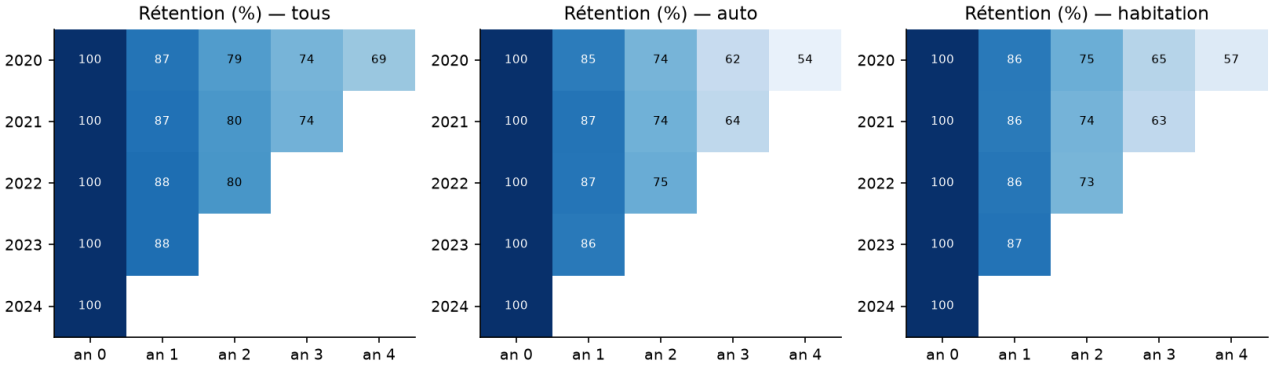


Figure 7 : les cohortes se ressemblent beaucoup. Environ 1 client sur 8 part la première année.

Auto + habitation. 35 % des clients ont eu les deux produits à un moment, mais seulement 3,1 % les avaient dès le départ (90 premiers jours). Pour comparer j'utilise la deuxième définition, sinon c'est biaisé (un client qui reste longtemps a plus de chances d'acheter un deuxième produit). Résultat : après 1 an, 97 % des multi-détenteurs sont encore là contre 87 % des autres (p-value < 0,001). Ça ne prouve pas une cause, mais vendre les deux produits ensemble semble aider à garder les clients.

4.2 Valeur des clients

Valeur d'un client = primes acquises − sinistres payés sur toute la période. Au total : 19 979 938 € − 11 221 001 € = 8 758 937 € pour 14 977 clients.

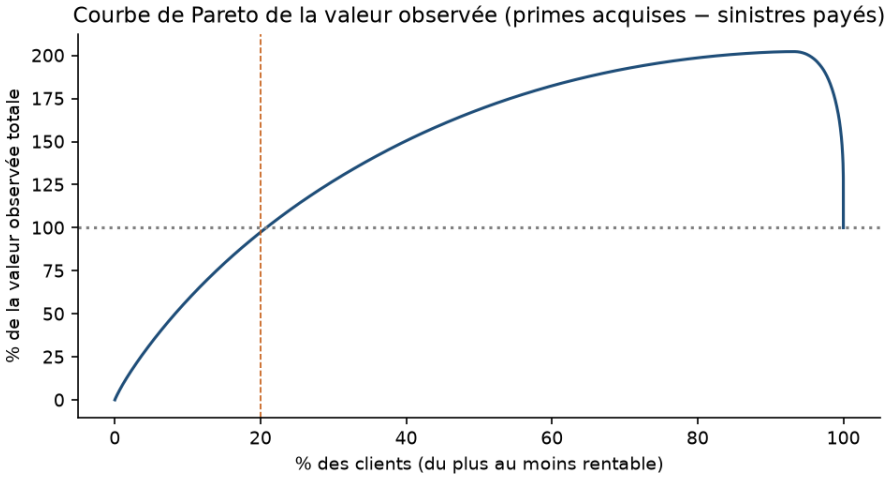


Figure 8 : la courbe dépasse 100 % puis redescend, car 1 010 clients (6,7 %) coûtent plus qu'ils ne rapportent (au total -8 953 601 €, dont -2 473 163 € pour un seul client).

Groupe	Clients	Valeur moy.	Primes moy.	Payé moy.	Ancienneté (ans)	Auto + hab.	Sinistré
Top 10 %	1 498	3 403 €	3 448 €	45 €	6,1	68 %	7 %
Autres	11 982	1 051 €	1 096 €	46 €	2,7	31 %	5 %
Bottom 10 %	1 497	-5 963 €	1 122 €	7 085 €	2,5	32 %	70 %

Tableau 11 : les meilleurs clients sont anciens et ont souvent les deux produits. Les moins bons ont surtout eu un sinistre (70 %), ils ne sont pas très différents des autres sinon.

4.3 Délais de gestion

Déclaration = jours entre le sinistre et la déclaration. 1er paiement = jours entre la déclaration et le premier paiement. Il n'y a pas de date de clôture dans les données, donc j'ai pris la date du dernier paiement pour les sinistres clôturés.

Garantie	Déclaration (médiane / P90)	1er paiement (médiane / P90)	Clôture (médiane / P90)
bris glace	6 j / 19 j	45 j / 106 j	92 j / 243 j
collision	5 j / 20 j	50 j / 118 j	80 j / 209 j
degat eaux	5 j / 19 j	52 j / 117 j	88 j / 223 j
incendie	6 j / 23 j	46 j / 133 j	76 j / 189 j
rc	5 j / 18 j	50 j / 108 j	89 j / 202 j
tempete	4 j / 17 j	54 j / 139 j	84 j / 221 j
vol	5 j / 25 j	46 j / 108 j	72 j / 203 j
toutes	5 j / 20 j	49 j / 114 j	83 j / 208 j

Tableau 12 : en général un sinistre est déclaré en 5 jours, payé une première fois en 49 jours et clôturé en 83 jours. Mais 10 % attendent plus de 114 jours pour être payés. Les garanties sont assez proches.

4.4 Audits antifraude

Important : les taux de fraude ci-dessous ne concernent que les 372 sinistres audités (13 % des sinistres), et ils n'ont pas été choisis au hasard. On ne peut donc pas en déduire le taux de fraude de tout le portefeuille. Taux global chez les audités : 9,9 %.

Critère	Valeur	Sinistres	Audités	Fraudes	Taux de fraude (audités)
delai declaration	Inconnu	15	3	1	33,3 %
delai declaration	a. 0-2 j	910	102	0	0,0 %
delai declaration	b. 3-7 j	856	100	0	0,0 %
delai declaration	c. 8-30 j	893	109	4	3,7 %
delai declaration	d. > 30 j	126	58	32	55,2 %
tranche reserve	a. 0 €	843	20	4	20,0 %
tranche reserve	b. < 1 k€	599	38	5	13,2 %
tranche reserve	c. 1-5 k€	857	74	12	16,2 %
tranche reserve	d. 5-20 k€	426	197	12	6,1 %
tranche reserve	e. ≥ 20 k€	75	43	4	9,3 %
garantie	BRIS_GLACE	334	13	4	30,8 %
garantie	COLLISION	693	66	9	13,6 %
garantie	DEGAT_EAUX	595	68	6	8,8 %
garantie	INCENDIE	109	49	4	8,2 %
garantie	RC	444	106	2	1,9 %
garantie	TEMPETE	235	11	0	0,0 %
garantie	VOL	390	59	12	20,3 %

Tableau 13 : taux de fraude confirmée selon plusieurs critères.

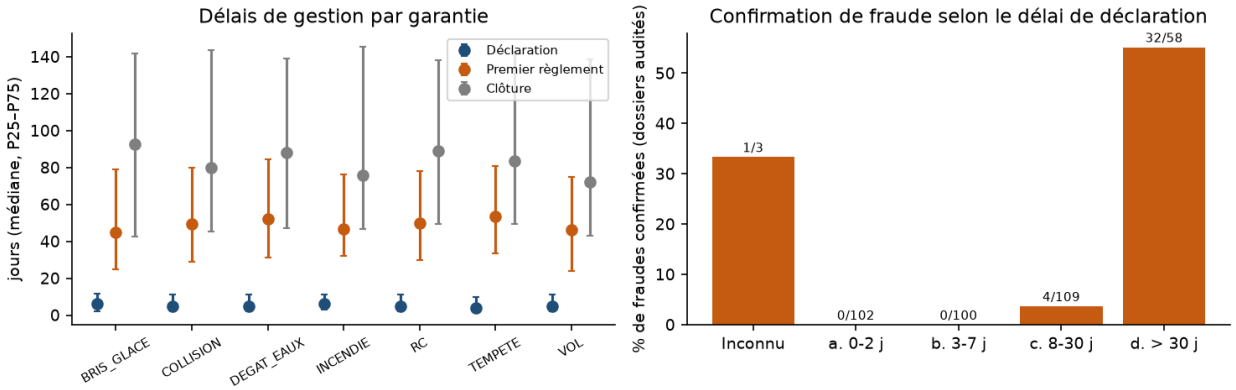


Figure 9 : délais par garantie et fraude selon le délai de déclaration.

Le critère qui marche le mieux est le délai de déclaration : quand le sinistre est déclaré plus de 30 jours après, 55 % des audits trouvent une fraude, contre aucune quand il est déclaré en moins de 7 jours. À l'inverse, les gros sinistres sont beaucoup audités mais avec peu de fraudes trouvées. **Montants** : les sinistres audités représentent 5 258 521 € de réserves. Les fraudes confirmées représentent 417 905 €, soit environ 1 123 € par audit. Si un audit coûte moins que ça, il est rentable ; je n'ai pas le coût d'un audit dans les données pour conclure. Problème : sur les fraudes confirmées, 397 791 € ont quand même été payés après l'audit (sur 487 280 € payés au total sur ces dossiers). → Il faudrait bloquer les paiements quand une fraude est confirmée et auditer en priorité les déclarations tardives.

5. Dashboard et documentation

5.1 Dashboard

Le dashboard est fait avec Streamlit. Il lit seulement les tables mart de la base. Chaque page se charge en moins de 2 secondes. Sans filtre, il affiche les mêmes chiffres que ce dossier : primes 19 979 938 €, fréquence 4,33 %, S/P 58,8 %, 13 645 contrats actifs au 30/06/2025.

Page	Contenu
Portefeuille	Les 6 indicateurs avec comparaison à l'année d'avant, courbes mensuelles, alerte rouge si le S/P dépasse 70 %.
Technique et clients	S/P par zone, formule, canal, âge ; évolution du S/P ; rétention par cohorte ; courbe de Pareto.
Exploitation	Dernier chargement par fichier, lignes rejetées par règle, résultat des tests, délais par garantie.
Définitions	Explication de chaque indicateur.

Filtres : période, produit, région, canal et zone, plus un bouton pour plafonner les gros sinistres. J'ai mis le seuil d'alerte à 70 % car un assureur dépense environ 30 % de ses primes en frais : au-dessus de 70 % de S/P, il ne gagne plus d'argent.

5.2 Automatisation

Un petit script (*pipeline/watch.py*) regarde toutes les 15 minutes si un nouveau fichier est arrivé et lance le pipeline. S'il y a une erreur, tout est annulé, l'erreur est écrite dans *logs/alertes.log* et peut être envoyée sur Teams ou Slack.

```
*/15 * * * * cd /opt/boreal && .venv/bin/python -m pipeline.watch --once
```

5.3 Documentation

Le README explique comment tout lancer en 5 commandes. Le catalogue (*docs/catalogue_donnees.md*) décrit les 48 tables et 517 colonnes. Il y a aussi un schéma d'architecture, le lignage du S/P et l'analyse RGPD dans le dossier docs.

Lignage du S/P

```
contrats.csv -> raw -> prep -> core.dim_contrat -> fact_exposition_mensuelle.prime_acquise  (dénominateur)
sinistres.jsonl + reglements_*.csv -> raw -> prep -> fact_sinistre.charge                   (numérateur)
-> mart.portefeuille_mensuel -> mart.kpi_segment.ratio_sp -> dashboard + dossier
```

5.4 RGPD

Il n'y a ni nom ni adresse, mais les données restent personnelles car elles sont seulement pseudonymisées (l'e-mail crypté peut être retrouvé avec le CRM). Données concernées : identifiant, e-mail crypté, date de naissance, région, CSP, sinistres et fraude. Le dashboard ne montre que des totaux. Durées proposées : 13 mois pour les couches brute et quarantaine, 5 ans après la fin du contrat pour le reste, 5 ans pour l'antifraude.

Couche	Supprimer un client
raw	Supprimer ses lignes (et à la source dans le CRM).
prep / quarantaine / core	Ces tables sont recalculées depuis raw : le client disparaît au lancement suivant (sauf dim_contrat à nettoyer à la main).
marts	Recalculés, plus de trace.

Annexes

A. Limites

• Les réserves ne sont pas mises à jour dans les données, donc 2024 et 2025 peuvent changer.
• Pas de date de clôture : j'ai utilisé le dernier paiement.
• Je suppose que la prime d'un contrat ne change pas pendant toute sa durée.
• Les sinistres pas encore déclarés au 30/06/2025 ne sont pas estimés (pas de prévision demandée).
• Les audits ne sont pas faits au hasard.

B. Contribution

Projet réalisé seul par Souleymane DJIBO (M2 Data Analyst, PMN) : 100 % du travail.

C. Requêtes utilisées

Quelques requêtes qui donnent les chiffres du dossier (toutes sont dans analysis/output/requetes_sources.json).

kpi_2020_2025

```
SELECT axe, modalite, exposition, primes_acquises, nb_sinistres_declares, nb_sinistres, nb_sans_suite, nb_rejetes, montant_paye, reserves, charge, charge_ecretee, frequence, cout_moyen, cout_moyen_ecrete, prime_moyenne, ratio_sp, ratio_sp_ecrete, taux_resiliation, resiliations, nb_graves FROM mart.kpi_segment WHERE periode='2020-2025' ORDER BY axe, modalite
```

decomposition

```
SELECT * FROM mart.decomposition_sp ORDER BY mesure, annee
```

base_bootstrap

```
WITH e AS (SELECT contrat_id, SUM(exposition_annees) expo, SUM(prime_acquise) prime, SUM(resiliation) resil FROM core.fact_exposition_mensuelle GROUP BY 1), s AS (SELECT contrat_id, SUM(avec_suite::INT) n, SUM(charge) ch, SUM(charge_ecretee) che FROM core.fact_sinistre GROUP BY 1) SELECT e.*, COALESCE(s.n,0) n, COALESCE(s.ch,0) ch, COALESCE(s.che,0) che, k.produit, k.zone_risque, k.canal FROM e JOIN core.dim_contrat k ON k.contrat_id=e.contrat_id AND k.is_current LEFT JOIN s ON s.contrat_id=e.contrat_id
```

retention

```
SELECT * FROM mart.retention_cohorte ORDER BY produit, cohorte, annee_anciennete
```

valeur_client

```
SELECT * FROM mart.valeur_client ORDER BY rang
```

delais

```
SELECT * FROM mart.delais_sinistres ORDER BY ordre, garantie
```

audits

```
SELECT * FROM mart.audits_criteres ORDER BY critere, modalite
```

fraude_paiements

```
SELECT COUNT(DISTINCT f.sinistre_id) nb_fraudes, SUM(r.montant) paye_total, SUM(CASE WHEN r.date_paiement > f.date_audit THEN r.montant ELSE 0 END) paye_apres_audit, SUM(CASE WHEN r.date_paiement <= f.date_audit THEN r.montant ELSE 0 END) paye_avant_audit FROM core.fact_sinistre f JOIN core.fact_reglement r USING (sinistre_id) WHERE f.fraude_confirmee = 1
```

reconciliation

```
SELECT (SELECT SUM(CAST(montant AS DECIMAL(18,2))) FROM raw.reglements) brut, (SELECT SUM(CAST(montant AS DECIMAL(18,2))) FROM core.fact_reglement) coeur, (SELECT SUM(CAST(b.montant AS DECIMAL(18,2))) FROM raw.reglements b WHERE (b._source_file,b._row_num) IN (SELECT _source_file,_row_num FROM quarantine.reglements WHERE rule_id='Q23')) doublons, (SELECT SUM(CAST(b.montant AS DECIMAL(18,2))) FROM raw.reglements b WHERE (b._source_file,b._row_num) IN (SELECT _source_file,_row_num FROM quarantine.reglements WHERE rule_id='Q24')) en_cascade
```

D. Exemples de règles qualité (SQL)

Trois règles expliquées (la liste complète est en annexe E) :

Q05 : Doublon métier (même e-mail + date de naissance) (200 lignes)

```
SELECT c.client_id::VARCHAR, c._source_file, c._row_num, 'absorbé par client '||m.client_id_survivant FROM prep.clients c JOIN prep.client_mapping m USING (client_id) WHERE m.rang > 1
```

Q09 : Date de résiliation antérieure à la date d'effet (20 lignes)

```
SELECT contrat_id::VARCHAR, _source_file, _row_num, date_effet||' > '||date_resiliation FROM prep.contrats WHERE date_resiliation < date_effet
```

Q23 : Paiement livré plusieurs fois (re-livraison) (32 lignes)

```
SELECT paiement_id::VARCHAR, _source_file, _row_num, 'déjà livré, livraison n°'||rang_livraison FROM prep.reglements WHERE rang_livraison > 1
```

E. Requêtes des 34 règles qualité

Pour chaque règle : la requête SQL qui renvoie les lignes en anomalie (stockée aussi dans la table meta.dq_rules).

Q01 · Date de naissance manquante · gravité mineur · 226 lignes · signaler
```
SELECT client_id::VARCHAR cle, _source_file, _row_num, 'date_naissance vide' detail FROM prep.clients WHERE fl_dn_manquante
```

Q02 · Date de naissance sentinelle 01/01/1890 · gravité majeur · 18 lignes · corriger
```
SELECT client_id::VARCHAR, _source_file, _row_num, date_naissance_brute FROM prep.clients WHERE fl_dn_sentinelle
```

Q03 · Âge invraisemblable au 1er contrat (<18 ou >100 ans) · gravité majeur · 722 lignes · corriger
```
SELECT client_id::VARCHAR, _source_file, _row_num, 'né le '||date_naissance_brute||', âge '||age_premier_contrat FROM prep.clie
E fl_age_invraisemblable
```

Q04 · Identifiant client dupliqué · gravité bloquant · 0 lignes · exclure
```
SELECT client_id::VARCHAR, _source_file, _row_num, 'client_id en double' FROM prep.clients WHERE client_id IN (SELECT client_id
ep.clients GROUP BY 1 HAVING COUNT(*)>1) OR client_id IS NULL
```

Q05 · Doublon métier (même e-mail + date de naissance) · gravité majeur · 200 lignes · fusionner
```
SELECT c.client_id::VARCHAR, c._source_file, c._row_num, 'absorbé par client '||m.client_id_survivant FROM prep.clients c JOIN
ent_mapping m USING (client_id) WHERE m.rang > 1
```

Q06 · Région ou CSP hors référentiel · gravité mineur · 0 lignes · signaler
```
SELECT client_id::VARCHAR, _source_file, _row_num, region||'/'||csp FROM prep.clients WHERE region NOT IN ('IDF','ARA','HDF','G
','PACA','GES','BFC','PDL','NOR','BRE','CVL','COR') OR csp NOT IN ('EMPLOYE','RETRAITE','CADRE','OUVRIER','INDEPENDANT','ETUDIA
```

Q07 · Identifiant contrat dupliqué ou vide · gravité bloquant · 0 lignes · exclure
```
SELECT contrat_id::VARCHAR, _source_file, _row_num, 'contrat_id en double' FROM prep.contrats WHERE contrat_id IN (SELECT contr
OM prep.contrats GROUP BY 1 HAVING COUNT(*)>1) OR contrat_id IS NULL
```

Q08 · Contrat rattaché à un client inexistant · gravité majeur · 0 lignes · exclure
```
SELECT contrat_id::VARCHAR, _source_file, _row_num, 'client '||client_id_source FROM prep.contrats k WHERE NOT EXISTS (SELECT 1
ep.clients c WHERE c.client_id = k.client_id_source)
```

Q09 · Date de résiliation antérieure à la date d'effet · gravité majeur · 20 lignes · exclure
```
SELECT contrat_id::VARCHAR, _source_file, _row_num, date_effet||' > '||date_resiliation FROM prep.contrats WHERE date_resiliati
e_effet
```

Q10 · Résiliation le jour de l'effet (durée nulle) · gravité mineur · 6 lignes · signaler
```
SELECT contrat_id::VARCHAR, _source_file, _row_num, 'effet = résiliation = '||date_effet FROM prep.contrats WHERE date_resiliat
te_effet
```

Q11 · Prime annuelle nulle ou négative · gravité majeur · 25 lignes · exclure
```
SELECT contrat_id::VARCHAR, _source_file, _row_num, 'prime = '||prime_annuelle FROM prep.contrats WHERE prime_annuelle IS NULL
_annuelle <= 0
```

Q12 · Valeur hors domaine (produit, formule, canal, zone, franchise) · gravité majeur · 0 lignes · exclure
```
SELECT contrat_id::VARCHAR, _source_file, _row_num, produit||'/'||formule||'/'||canal||'/'||zone_risque FROM prep.contrats WHER
t NOT IN ('AUTO','HABITATION') OR formule NOT IN ('ESSENTIELLE','CONFORT','PREMIUM') OR canal NOT IN ('AGENT','COURTIER','WEB')
_risque NOT BETWEEN 1 AND 5 OR franchise NOT IN (150,300,500,1000) OR produit IS NULL OR formule IS NULL OR canal IS NULL OR zo
e IS NULL OR franchise IS NULL
```

Q13 · Attributs incohérents avec le produit · gravité mineur · 0 lignes · signaler
```
SELECT contrat_id::VARCHAR, _source_file, _row_num, produit FROM prep.contrats WHERE (produit='AUTO' AND (puissance_cv IS NULL
_malus IS NULL OR surface_m2 IS NOT NULL)) OR (produit='HABITATION' AND (surface_m2 IS NULL OR puissance_cv IS NOT NULL))
```

Q14 · Date d'effet manquante ou illisible · gravité majeur · 0 lignes · exclure
```
SELECT contrat_id::VARCHAR, _source_file, _row_num, COALESCE(date_effet_brute,'vide') FROM prep.contrats WHERE date_effet IS NU
ate_resiliation IS NULL AND date_resiliation_brute IS NOT NULL)
```

Q15 · Dates postérieures à l'extraction · gravité majeur · 0 lignes · exclure
```
SELECT contrat_id::VARCHAR, _source_file, _row_num, date_effet||' / '||COALESCE(date_resiliation::VARCHAR,'') FROM prep.contrat
date_effet > DATE '2025-06-30' OR date_resiliation > DATE '2025-06-30'
```

Q16 · Identifiant sinistre dupliqué ou vide · gravité bloquant · 0 lignes · exclure
```
SELECT sinistre_id::VARCHAR, _source_file, _row_num, 'doublon' FROM prep.sinistres WHERE sinistre_id IN (SELECT sinistre_id FRO
inistres GROUP BY 1 HAVING COUNT(*)>1) OR sinistre_id IS NULL
```

Q17 · Sinistre sur contrat inexistant ou en quarantaine · gravité majeur · 5 lignes · exclure
```
SELECT s.sinistre_id::VARCHAR, s._source_file, s._row_num, 'contrat '||s.contrat_id FROM prep.sinistres s WHERE NOT EXISTS (SEL
OM prep.contrats k WHERE k.contrat_id = s.contrat_id) OR s.contrat_id::VARCHAR IN (SELECT cle FROM quarantine.contrats)
```

Q18 · Déclaration antérieure à la survenance · gravité mineur · 15 lignes · signaler
```
SELECT sinistre_id::VARCHAR, _source_file, _row_num, date_survenance||' > '||date_declaration FROM prep.sinistres WHERE date_de
n < date_survenance
```

Q19 · Survenance hors période de couverture du contrat · gravité majeur · 18 lignes · signaler
```
SELECT s.sinistre_id::VARCHAR, s._source_file, s._row_num, 'survenance '||s.date_survenance||' / contrat '||k.date_effet||'→'||
(k.date_resiliation::VARCHAR,'') FROM prep.sinistres s JOIN prep.contrats k USING (contrat_id) WHERE s.date_survenance < k.date
R s.date_survenance > k.date_resiliation
```

Q20 · Garantie incompatible avec le produit · gravité majeur · 0 lignes · exclure
```
SELECT s.sinistre_id::VARCHAR, s._source_file, s._row_num, s.garantie||' sur '||k.produit FROM prep.sinistres s JOIN prep.contr
ING (contrat_id) WHERE (k.produit='AUTO' AND s.garantie NOT IN ('COLLISION','RC','VOL','BRIS_GLACE')) OR (k.produit='HABITATION
garantie NOT IN ('DEGAT_EAUX','INCENDIE','TEMPETE','VOL'))
```

Q21 · Statut incohérent avec la réserve · gravité mineur · 0 lignes · signaler
```
SELECT sinistre_id::VARCHAR, _source_file, _row_num, statut||' / réserve '||reserve_initiale FROM prep.sinistres WHERE (statut
ETE','SANS_SUITE') AND reserve_initiale > 0) OR (statut IN ('OUVERT','CLOTURE') AND COALESCE(reserve_initiale,0) <= 0) OR statu
 ('OUVERT','CLOTURE','REJETE','SANS_SUITE')
```

Q22 · Réserve atypique (> 500 k€) : sinistre grave à isoler · gravité mineur · 1 lignes · signaler
```
SELECT sinistre_id::VARCHAR, _source_file, _row_num, 'réserve '||reserve_initiale FROM prep.sinistres WHERE reserve_initiale >
```

Q23 · Paiement livré plusieurs fois (re-livraison) · gravité majeur · 32 lignes · exclure
```
SELECT paiement_id::VARCHAR, _source_file, _row_num, 'déjà livré, livraison n°'||rang_livraison FROM prep.reglements WHERE rang
on > 1
```

Q24 · Paiement sur sinistre inexistant ou en quarantaine · gravité majeur · 1 lignes · exclure
```
SELECT r.paiement_id::VARCHAR, r._source_file, r._row_num, 'sinistre '||r.sinistre_id FROM prep.reglements r WHERE NOT EXISTS (
 FROM prep.sinistres s WHERE s.sinistre_id = r.sinistre_id) OR r.sinistre_id::VARCHAR IN (SELECT cle FROM quarantine.sinistres)
```

Q25 · Montant nul, négatif ou illisible · gravité majeur · 0 lignes · exclure
```
SELECT paiement_id::VARCHAR, _source_file, _row_num, 'montant '||COALESCE(montant::VARCHAR,'illisible') FROM prep.reglements WH
ant IS NULL OR montant <= 0 OR paiement_id IS NULL
```

Q26 · Paiement avant déclaration ou après extraction · gravité majeur · 0 lignes · exclure
```
SELECT r.paiement_id::VARCHAR, r._source_file, r._row_num, r.date_paiement::VARCHAR FROM prep.reglements r LEFT JOIN prep.sinis
SING (sinistre_id) WHERE r.date_paiement IS NULL OR r.date_paiement > DATE '2025-06-30' OR r.date_paiement < s.date_declaration
```

Q27 · Paiement sur sinistre rejeté ou sans suite · gravité majeur · 0 lignes · signaler
```
SELECT r.paiement_id::VARCHAR, r._source_file, r._row_num, s.statut FROM prep.reglements r JOIN prep.sinistres s USING (sinistr
ERE s.statut IN ('REJETE','SANS_SUITE')
```

Q28 · Fichier au schéma non standard (colonnes renommées/permutées) · gravité mineur · 86 lignes · signaler
```
SELECT paiement_id::VARCHAR, _source_file, _row_num, _header_original FROM prep.reglements WHERE _header_original <> 'paiement_
tre_id,date_paiement,montant'
```

Q29 · Paiement hors du mois de son fichier de livraison · gravité mineur · 32 lignes · signaler
```
SELECT paiement_id::VARCHAR, _source_file, _row_num, 'payé '||date_paiement||' livré '||mois_fichier FROM prep.reglements WHERE
E(date_paiement,'%Y-%m') <> mois_fichier
```

Q30 · Cumul payé > 2 fois la réserve initiale du sinistre · gravité mineur · 17 lignes · signaler
```
SELECT s.sinistre_id::VARCHAR, s._source_file, s._row_num, 'payé '||ROUND(p.tot,2)||' / réserve '||s.reserve_initiale FROM prep
es s JOIN (SELECT sinistre_id, SUM(montant) tot FROM prep.reglements WHERE rang_livraison=1 GROUP BY 1) p USING (sinistre_id) W
ot > 2*s.reserve_initiale
```

Q31 · Audit sur sinistre inexistant ou en quarantaine · gravité majeur · 0 lignes · exclure
```
SELECT a.sinistre_id::VARCHAR, a._source_file, a._row_num, 'sinistre absent' FROM prep.audits a WHERE NOT EXISTS (SELECT 1 FROM
nistres s WHERE s.sinistre_id = a.sinistre_id) OR a.sinistre_id::VARCHAR IN (SELECT cle FROM quarantine.sinistres)
```

Q32 · Plusieurs audits pour un même sinistre · gravité majeur · 0 lignes · exclure
```
SELECT sinistre_id::VARCHAR, _source_file, _row_num, 'audit en double' FROM (SELECT *, ROW_NUMBER() OVER (PARTITION BY sinistre
R BY date_audit DESC, _row_num) rn FROM prep.audits) WHERE rn > 1
```

Q33 · Audit antérieur à la déclaration ou postérieur à l'extraction · gravité mineur · 0 lignes · signaler
```
SELECT a.sinistre_id::VARCHAR, a._source_file, a._row_num, a.date_audit::VARCHAR FROM prep.audits a JOIN prep.sinistres s USING
re_id) WHERE a.date_audit < s.date_declaration OR a.date_audit > DATE '2025-06-30'
```

Q34 · Indicateur de fraude hors {0,1} · gravité majeur · 0 lignes · exclure
```
SELECT sinistre_id::VARCHAR, _source_file, _row_num, COALESCE(fraude_confirmee::VARCHAR,'vide') FROM prep.audits WHERE fraude_c
 IS NULL OR fraude_confirmee NOT IN (0,1)
```

F. Questions possibles à l'oral

Si un mois est livré deux fois ? Si c'est le même fichier, il est ignoré. Si c'est un autre nom, les paiements déjà connus partent en quarantaine (règle Q23) et rien ne change dans le cœur. C'est vérifié par un test pytest.

Comment savoir si la base est d'accord avec les fichiers ? Les tests T05 et T06 vérifient que brut = cœur + quarantaine, en nombre de lignes et en euros.

Pourquoi un grain au mois ? Pour calculer l'exposition exacte sur n'importe quelle période et comparer avec l'année d'avant.